



TEDdy

Calegari Andrea 1041183
Polver Marco 1040386
Del Prete Giovanni 1035205



Watch next code

```
#READ NEXT VIDEO DATASET
```

```
next_video_dataset_path = "s3://unibg-cloud-data/watch_next_dataset.csv"
```

```
next_video_dataset = spark.read.option("header","true").csv(next_video_dataset_path)
```

```
next_video_dataset_agg = next_video_dataset.groupBy(col("idx").alias("idx_ref_2")).agg(collect_list("watch_next_idx").alias("watch_next_idx"))
```

```
# CREATE THE AGGREGATE MODEL, ADD TAGS TO TEDX_DATASET
```

```
#agg = aggregate collect list crea un array vero e proprio in base al tag
```

```
tags_dataset_agg = tags_dataset.groupBy(col("idx").alias("idx_ref")).agg(collect_list("tag").alias("tags"))
```

```
#controllo dello schema
```

```
tags_dataset_agg.printSchema()
```

```
#unisco il dataset principale con un array di tag per ogni id
```

```
tedx_dataset_agg = tedx_dataset.join(tags_dataset_agg, tedx_dataset.idx == tags_dataset_agg.idx_ref, "left").drop("idx_ref")
```

```
tedx_dataset_agg_next = tedx_dataset_agg.join(next_video_dataset_agg, tedx_dataset_agg.idx == next_video_dataset_agg.idx_ref_2, "left")
```

```
.drop("idx_ref_2") \
```

```
.select(col("idx").alias("_id"), col("*")) \
```

```
.drop("idx") \
```

```
#converto idx in _id per mongoDB per evitare che lo inventi mongoDB
```



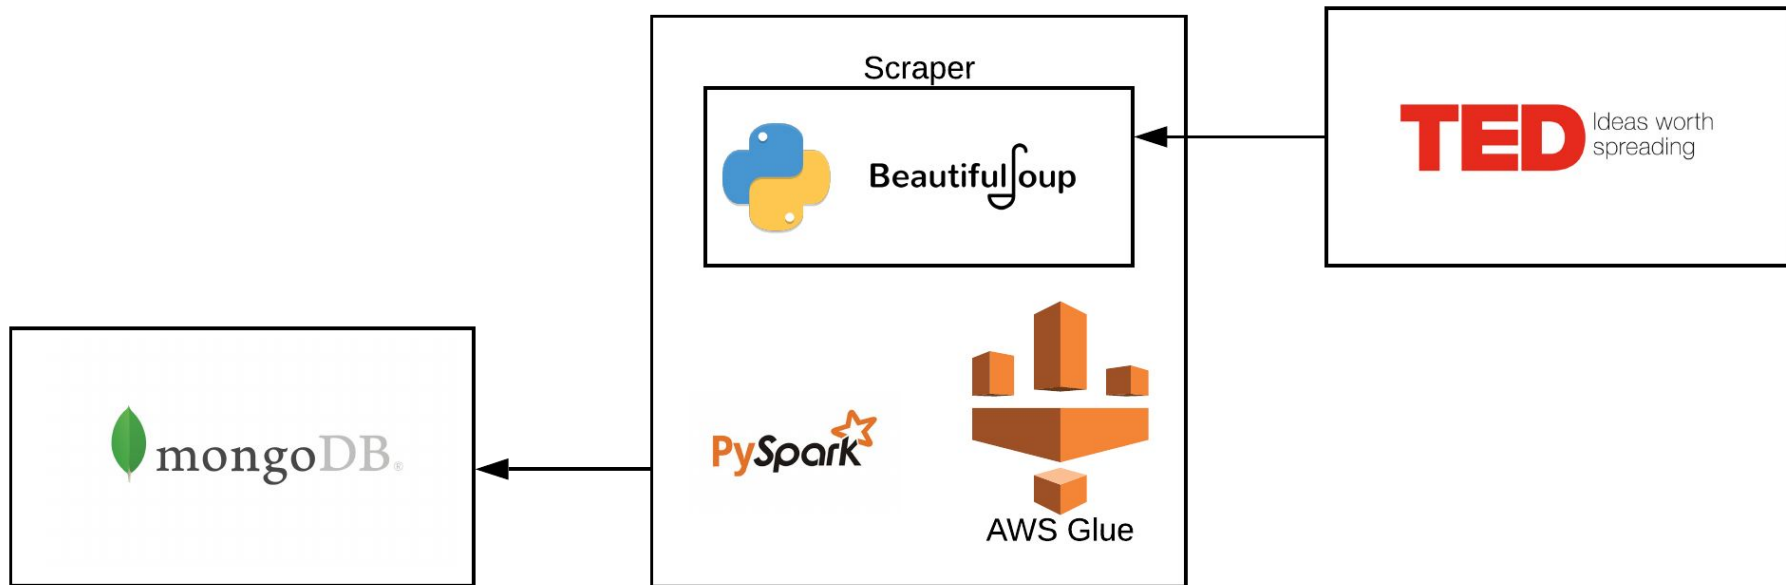
Watch next result



```
_id: "5be32167a2dcc08470287a6029b7e4c5"  
main_speaker: "Rabbi Lord Jonathan Sacks"  
title: "How we can navigate the coronavirus pandemic with courage and hope"  
details: "Rabbi Lord Jonathan Sacks offers thoughts on how we can navigate the c..."  
posted: "Posted Mar 2020"  
url: "https://www.ted.com/talks/rabbi_lord_jonathan_sacks_how_we_can_navigat..."  
tags: Array  
  0: "TED"  
  1: "talks"  
  2: "community"  
  3: "social change"  
  4: "humanity"  
  5: "coronavirus"  
  6: "pandemic"  
  7: "politics"  
  8: "global issues"  
  9: "religion"  
  10: "future"  
  11: "TED Connects"  
  12: "society"  
  13: "family"  
watch_next_ids: Array  
  0: "396f4daa2aa5b76bfa206815ac5abf58"  
  1: "396f4daa2aa5b76bfa206815ac5abf58"  
  2: "9f7b1654e792011b7e1c6f4288520226"  
  3: "586938c5a53d9b916498a893248a5da3"  
  4: "586938c5a53d9b916498a893248a5da3"  
  5: "9f7b1654e792011b7e1c6f4288520226"  
  6: "801e86946c2329fd5726edc0bb3e963d"  
  7: "801e86946c2329fd5726edc0bb3e963d"  
  8: "9f7b1654e792011b7e1c6f4288520226"  
  9: "140312d5f579d24f8ecda7715fc3377c"  
  10: "140312d5f579d24f8ecda7715fc3377c"
```



Scraper





Scraper

- Utilizzo di BeautifulSoup invece di Selenium, vista l'impossibilità di avviare un browser in AWS Glue
- Problema: impossibilità da parte di BeautifulSoup di accedere a codice HTML generato da ReactJS
→ impossibilità di accedere ai dati riguardanti i "next watch"



PROBLEM SOLVED

Utilizziamo tecniche di ML per consigliare il prossimo video



Scraper

- Problema: difficoltà nella creazione di file all'interno di un bucket S3 da job AWS Glue
- Appesantimento del sistema (scrittura su file csv e successiva lettura del file per aggiornamento DB)



PROBLEM SOLVED

Caricamento diretto dei risultati su Atlas MongoDB



Scraper

- Trigger mensile per l'aggiornamento del DB. La frequenza mensile è stata una scelta cost-driven, ma in produzione potremmo impostare una frequenza maggiore

Trigger properties

Name	daily_tedx_talks_update
Tags	-
Trigger type	Schedule
Schedule	At 02:55 PM, on day 1 of the month
Associated Workflow	-



Scraper

Link allo script: https://github.com/cale96/tecnologie_cloud_mobile/blob/master/scraper/scraper.py